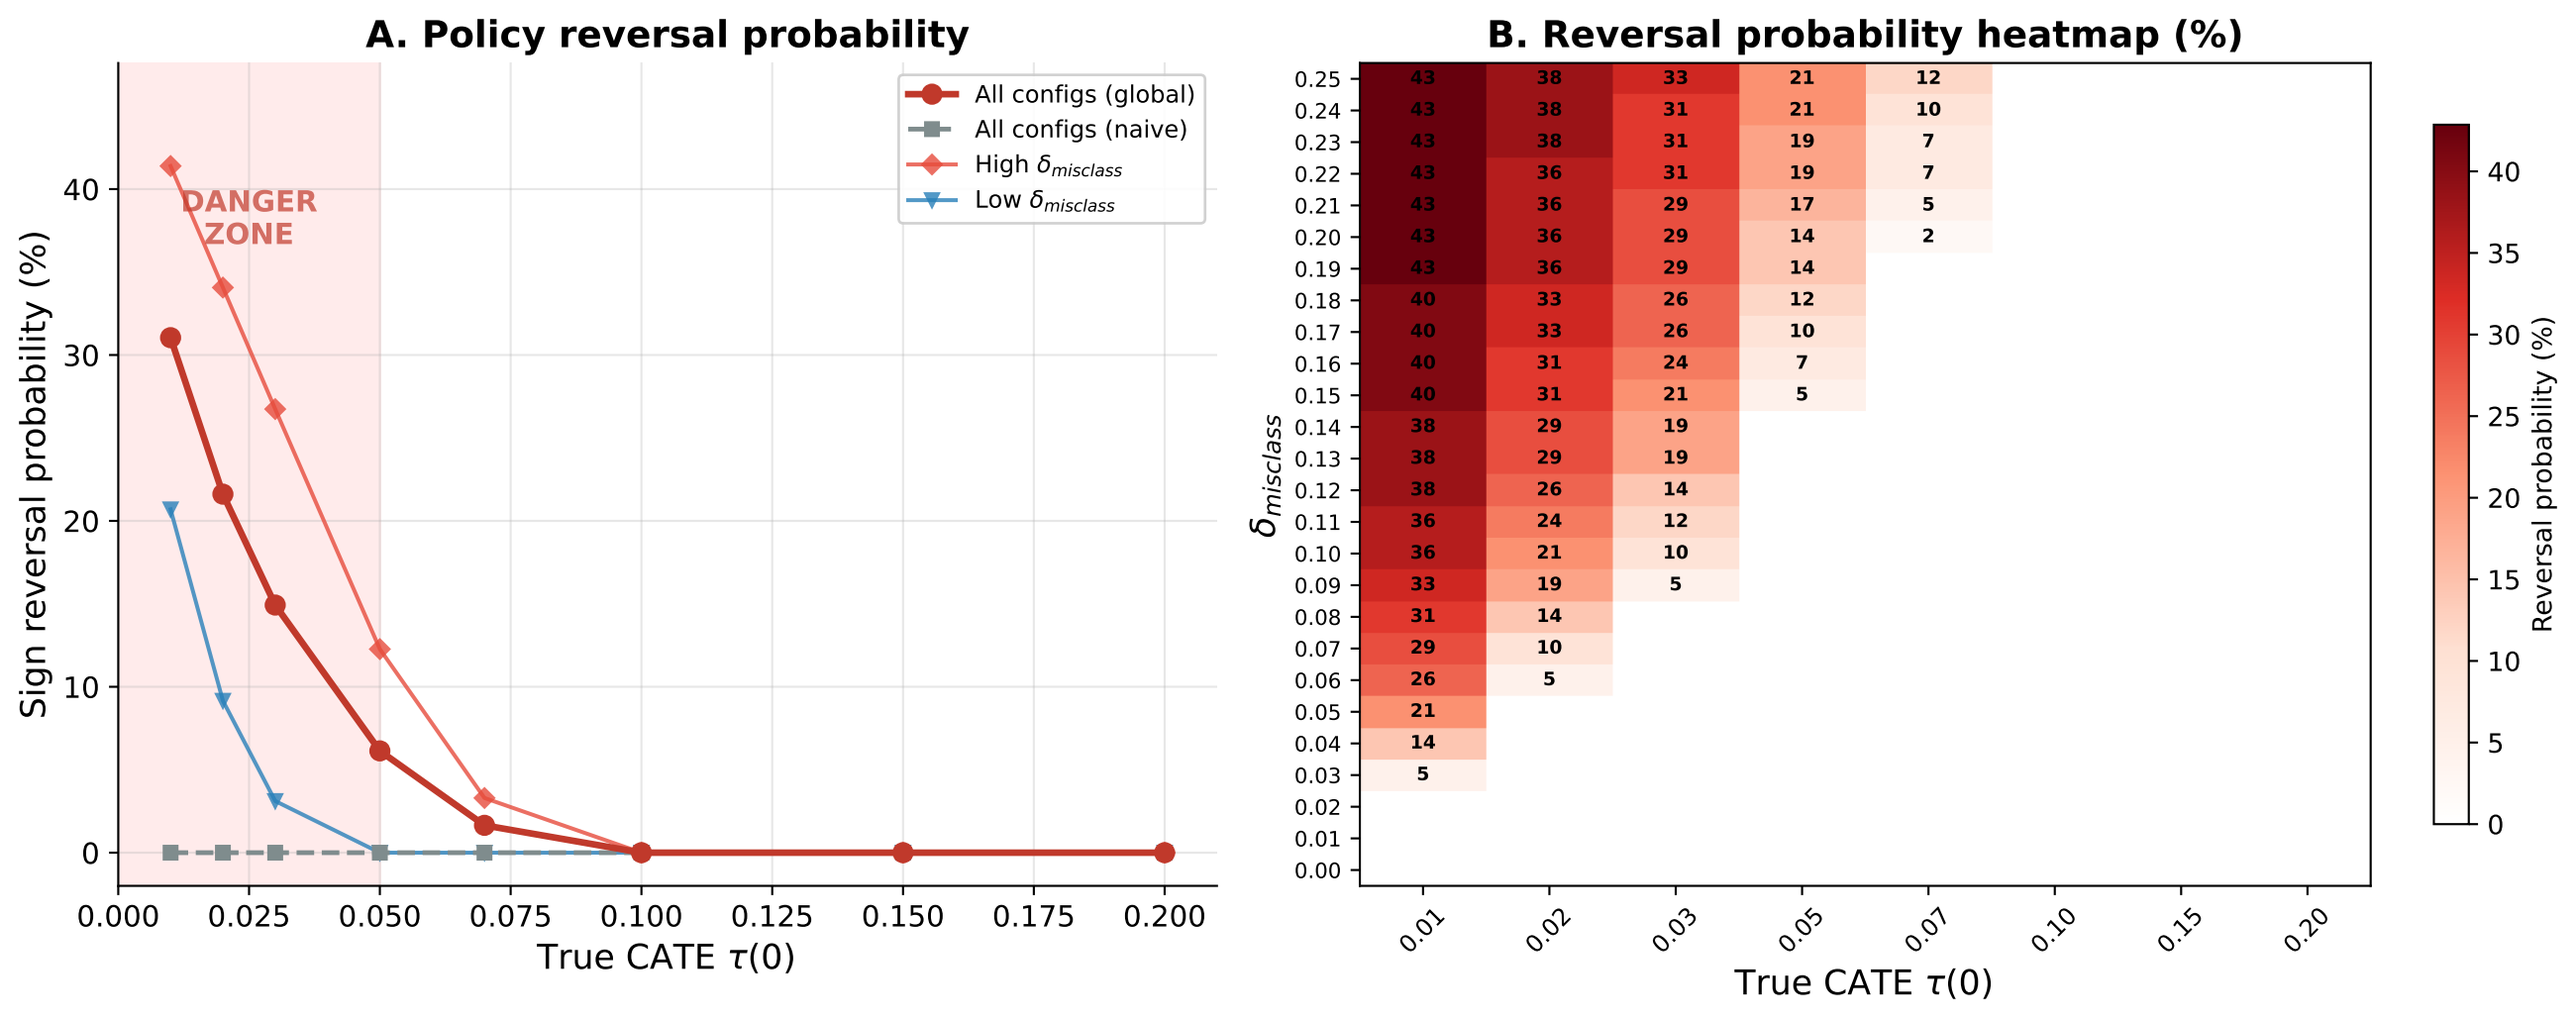
A. Policy reversal probability
DANGER ZONE
All configs (global)
All configs (naive)
High $\delta_{misclass}$
Low $\delta_{misclass}$
Sign reversal probability (%)
True CATE $\tau(0)$
0.000
0.025
0.050
0.075
0.100
0.125
0.150
0.175
0.200
0
10
20
30
40
B. Reversal probability heatmap (%)
$\delta_{misclass}$
0.25 43 38 33 21 12
0.24 43 38 31 21 10
0.23 43 38 31 19 7
0.22 43 36 31 19 7
0.21 43 36 29 17 5
0.20 43 36 29 14 2
0.19 43 36 29 14
0.18 40 33 26 12
0.17 40 33 26 10
0.16 40 31 24 7
0.15 40 31 21 5
0.14 38 29 19
0.13 38 29 19
0.12 38 26 14
0.11 36 24 12
0.10 36 21 10
0.09 33 19 5
0.08 31 14
0.07 29 10
0.06 26 5
0.05 21
0.04 14
0.03 5
0.02
0.01
0.00
0.01
0.02
0.03
0.05
0.07
0.10
0.15
0.20
True CATE $\tau(0)$
Reversal probability (%)
0
5
10
15
20
25
30
35
40