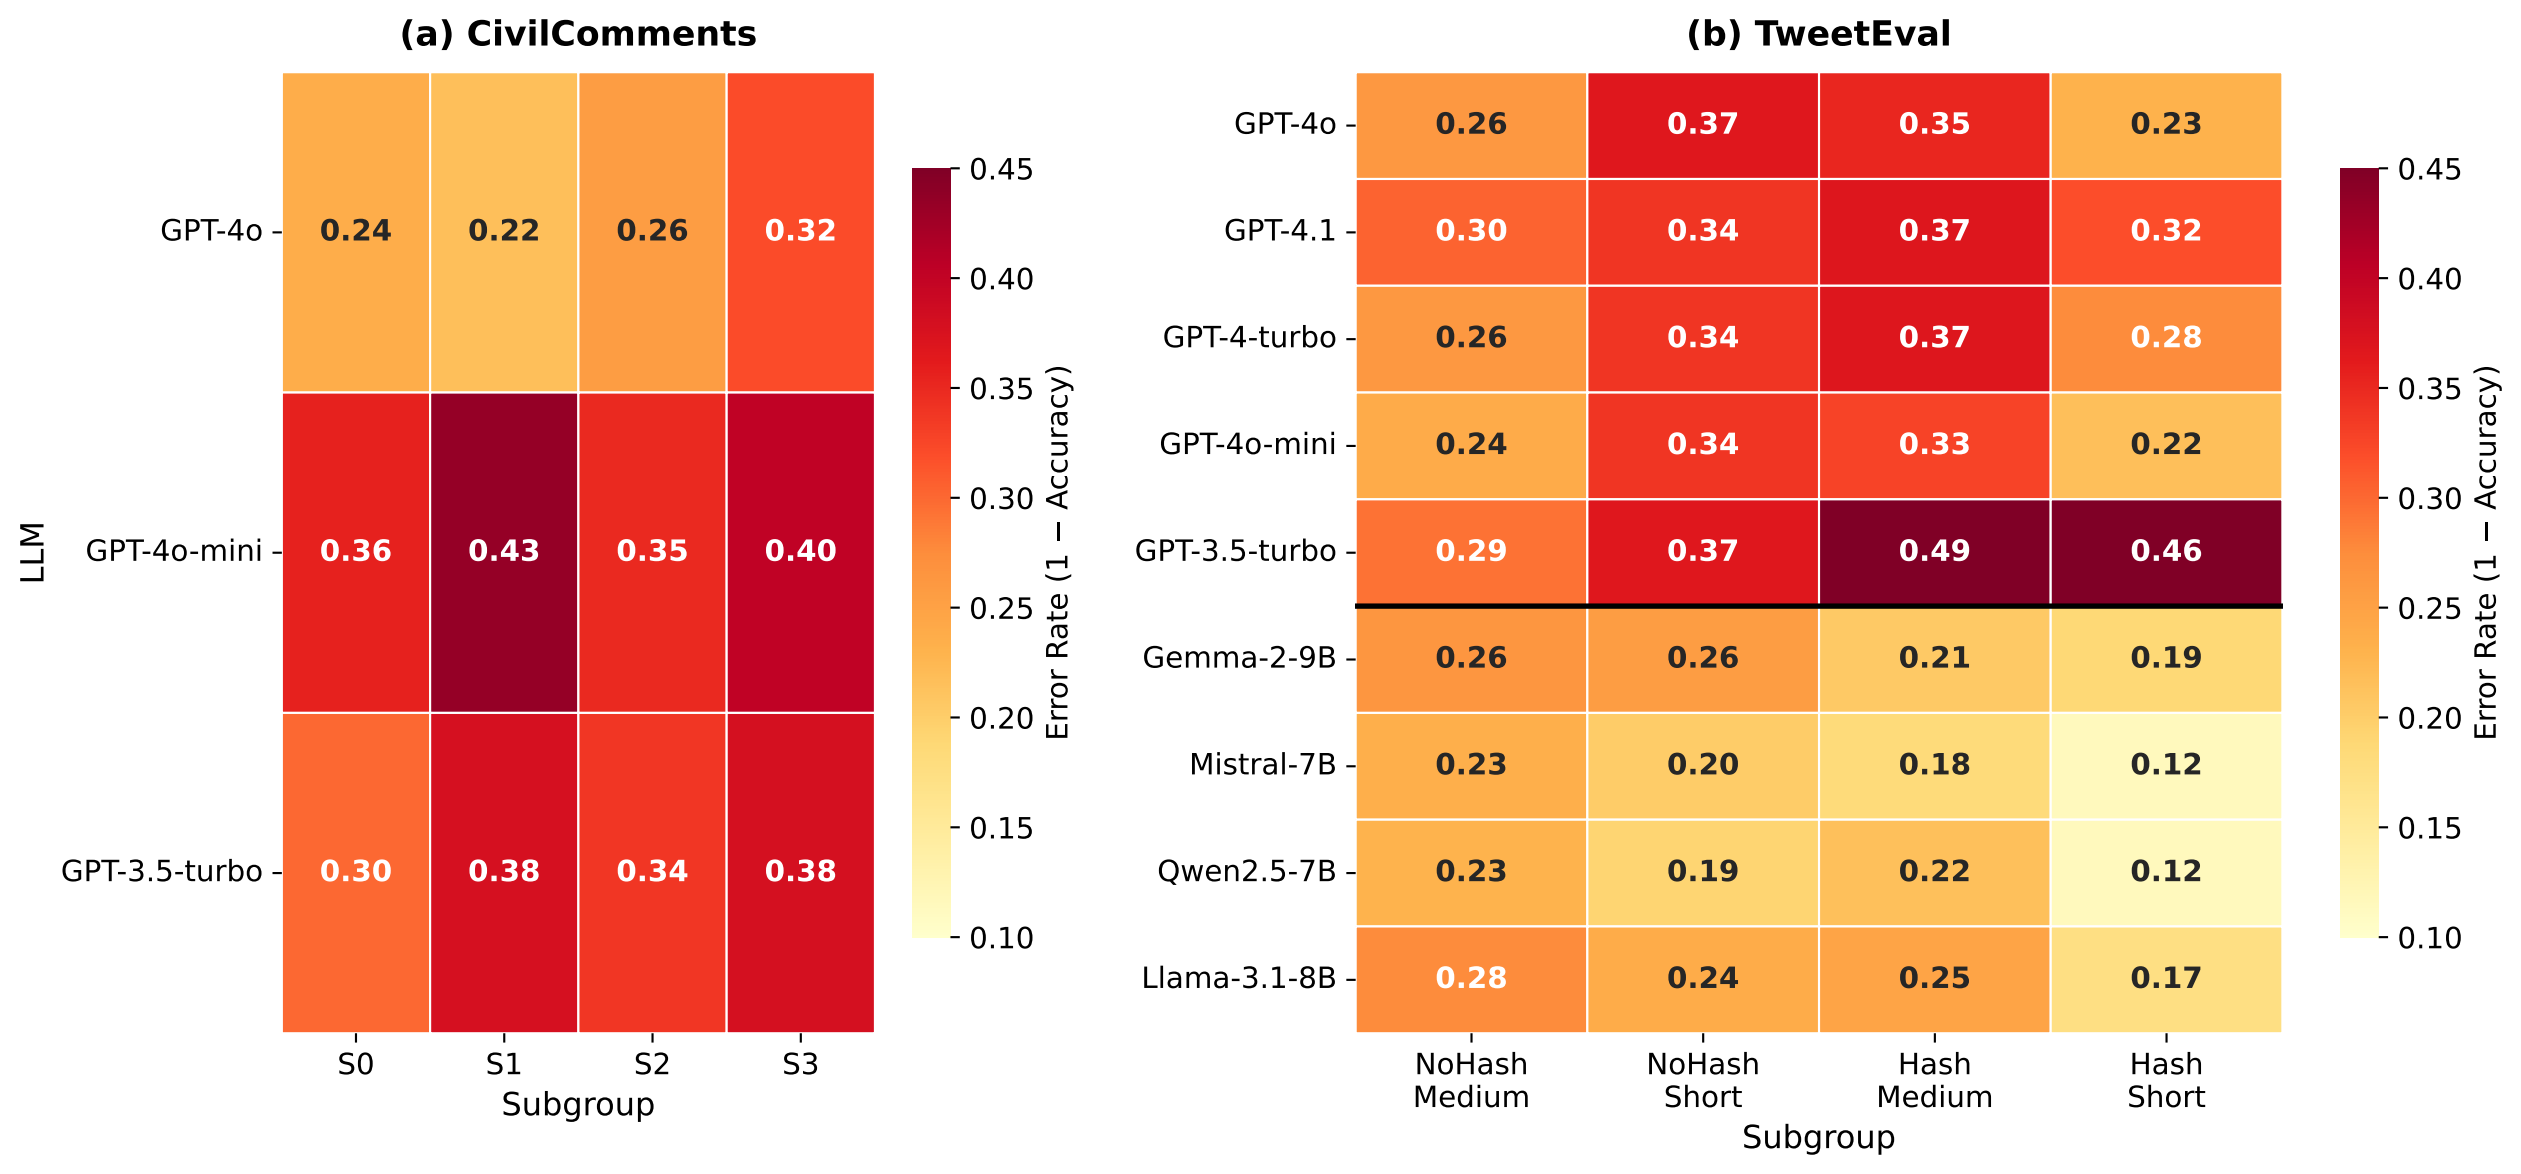
(a) CivilComments
GPT-4o
GPT-4o-mini
GPT-3.5-turbo
LLM
0.24
0.22
0.26
0.32
0.36
0.43
0.35
0.40
0.30
0.38
0.34
0.38
S0
S1
S2
S3
Subgroup
0.45
0.40
0.35
0.30
0.25
0.20
0.15
0.10
Error Rate (1 − Accuracy)
(b) TweetEval
GPT-4o
GPT-4.1
GPT-4-turbo
GPT-4o-mini
GPT-3.5-turbo
Gemma-2-9B
Mistral-7B
Qwen2.5-7B
Llama-3.1-8B
0.26
0.37
0.35
0.23
0.30
0.34
0.37
0.32
0.26
0.34
0.37
0.28
0.24
0.34
0.33
0.22
0.29
0.37
0.49
0.46
0.26
0.26
0.21
0.19
0.23
0.20
0.18
0.12
0.23
0.19
0.22
0.12
0.28
0.24
0.25
0.17
NoHash Medium
NoHash Short
Hash Medium
Hash Short
Subgroup
0.45
0.40
0.35
0.30
0.25
0.20
0.15
0.10
Error Rate (1 − Accuracy)