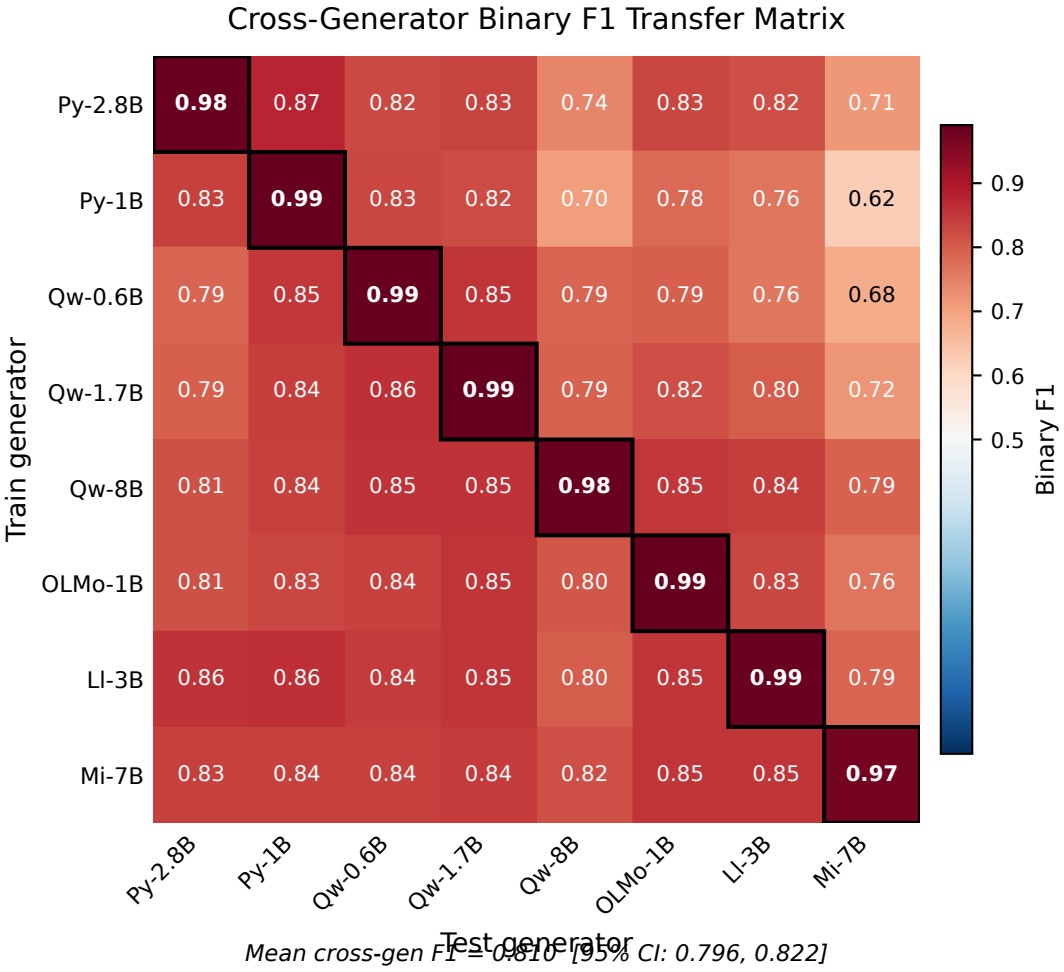
Cross-Generator Binary F1 Transfer Matrix
Train generator
Test generator
Py-2.8B
Py-1B
Qw-0.6B
Qw-1.7B
Qw-8B
OLMo-1B
Ll-3B
Mi-7B
0.98 0.87 0.82 0.83 0.74 0.83 0.82 0.71
0.83 0.99 0.83 0.82 0.70 0.78 0.76 0.62
0.79 0.85 0.99 0.85 0.79 0.79 0.76 0.68
0.79 0.84 0.86 0.99 0.79 0.82 0.80 0.72
0.81 0.84 0.85 0.85 0.98 0.85 0.84 0.79
0.81 0.83 0.84 0.85 0.80 0.99 0.83 0.76
0.86 0.86 0.84 0.85 0.80 0.85 0.99 0.79
0.83 0.84 0.84 0.84 0.82 0.85 0.85 0.97
Binary F1
0.9
0.8
0.7
0.6
0.5
Mean cross-gen F1 = 0.810 [95% CI: 0.796, 0.822]