# AI for AI：高层调优目标与研究任务

2026-08-02

## 研究方向

本研究关注如何用 AI 改进 AI 研发本身，即 **AI for AI**。调优目标不局限于某一次回答或 某一道题，而是提升 AI 系统完成真实研发任务的整体能力，使其能够在计算优化、软件工程、机器学习实验和科学研究中产出更高质量、更高效率且可验证的结果。

我们希望在多类 benchmark 和具体任务上理解这种能力的边界：哪些目标可以通过明确的评价 信号持续优化，哪些开放问题要求系统在看不到中间分数的情况下独立完成研究，以及这些能力 能否在不同任务和领域中稳定复现。

## 高层调优目标

- **结果质量**：提高任务最终产物的正确性、完整性和专业价值；
- **计算与工程效率**：在满足任务约束的前提下改善运行速度、资源使用和软件性能；
- **研究自主性**：增强问题理解、方法选择、实验执行、调试和结果分析能力；
- **稳健性**：减少对单一任务、单一评价形式或偶然高分的依赖；
- **可验证性**：形成可复现、可审计并能够由独立评测确认的研究与工程产物。

这些目标共同指向一种更广泛的能力：AI 不仅能够生成候选答案，还能够围绕一个真实目标完成 连续的研发工作，并在不同反馈条件下改善最终结果。

## 两类任务设置

### 有客观分数反馈的优化任务

第一类任务能够提供明确、可重复的评价，例如正确率、运行时间、加速比、内存效率或模型质量 指标。分数可以用于比较不同结果，并帮助系统判断改进是否真实有效。

这类任务适合研究持续优化能力，典型场景包括 GPU kernel、编译与程序性能、真实代码仓库中的 性能工程，以及机器学习实验与工程任务。

### 隐藏评分的开放式 Auto-Research 任务

第二类任务在执行过程中不提供中间分数。系统只能看到研究目标、输入资料和交付要求，看不到 私有参考答案、评分配置或当前表现，需要独立完成方法选择、实验实现、分析和结果交付，最终再 由外部评测统一判断质量。

这类设置更接近真实研究：研究者通常无法在每一步立即获得标准答案。它重点考察科学判断、长程规划、失败恢复和完整研究产出的能力，而不是根据即时分数反复试探。

两类设置具有互补性。可见分数任务适合检验优化效率和稳定性；隐藏评分任务则用于判断系统在 缺少即时反馈时，能否仍然完成有价值、可验证的研究工作。

## Benchmark 与任务方向

- **AI 计算与 GPU 效率**：KernelBench、Atrex-Bench 和 KernelBenchX，用于评价 AI 计算实现的正确性和 运行效率。
- **代码与系统性能**：CompilerGym、PIE、EffiBench 和 SWE-Perf，覆盖编译优化、程序效率和真实软件工程。
- **机器学习实验与工程**：MLAgentBench 和 MLE-bench，用于评价端到端机器学习实验和工程结果。
- **开放式 AI 研究**：ResearchGym 面向端到端 AI 研究任务；ASI-Bench 面向跨自然科学领域的 project-level AI for Science 工作流。

ASI-Bench 代表隐藏评分的 auto-research 场景。任务要求系统理解科学目标、检查数据、选择方法、完成实现与调试，并交付代码、数据、图表或报告等可验证产物。公开运行可以在不加载评分器的 模式下完成，私有参考答案和评分配置不会随任务材料提供，结果在提交后再进行独立评价。

## 关键研究问题

1. 客观分数反馈能否带来稳定、可复现的工程与实验改进?
2. 在看不到中间分数时，AI 能否独立完成有价值的开放式研究任务?
3. 从计算优化到科学研究，哪些能力可以跨任务、跨 benchmark 延伸?
4. 如何评价开放研究的质量，同时避免系统只针对已知评分规则进行优化?